


SHS FINAL BENCHMARK 100

Evolving Graph RAG

검색할수록 스스로 좋아지는 self-evolving Graph RAG

bwkim • 2026. 07



RAG가 검색 경험에서 배울 수 있다면?

01

멈춰 있는 시스템

인덱싱이 끝나면 그대로 고정 — 천 번을 검색해도 품질은 첫날과 같다.

02

반복되는 실패

어떤 질문이 어떻게 어긋나는지 기억하지 못해, 같은 실수를 되풀이한다.

03

버려지는 신호

질문과 검색 결과의 관계는 "무엇이 통했는지" 말해주는 데이터인데, 응답 후 버려진다.

GOAL 검색 기록을 재료로, LLM-wiki처럼 그래프를 진화 — 서빙 지연 · 정답 참조 · 회귀 없이

서빙은 빠르게, 학습은 뒤에서

Analyze

플랜 캐시 → 롤 →
새 질문만 심층 분석
(쿼리 분해 · 키워드
추출)



SERVE 최적 쿼리 경로

키워드 · 벡터 · 그래프 채널 조합 → 구조 그래프 이웃 확장 → 융합 랭킹 → Answer

EVOLVE 백그라운드 진화

분해 쿼리별 리트리브 로그 → 품질 채점 → 강화 / 감쇠 · 새 관계 · 전략 갱신 → SG + KG → 다음 라운드

쿼리 경로

키워드 쿼링

질문에서 핵심 키워드를 뽑아 벡터와 별도의 정확·일치 채널로도 검색 — ID·코드성 질문은 키워드 경로로 강제 라우팅.

캐시 히트

키워드 지문이 거의 같고 저장된 플랜의 품질이 기준선 이상일 때만 재사용 — 골조가 비슷하면 통했던 전략을 다시 쓴다.

품질 채점

정답 없이 계산하는 신뢰도 — 유사도 강도 · 랭킹 간 문서 합의도 · 용어 커버리지의 합성. 기준선은 자가보정.

EVOLVING 전략

SG 강화 · 감쇠

질의와 그 검색 결과들 사이의 관계(공동 검색 통계)로 문서 연결을 강화하고, 안 쓰이는 연결은 서서히 감쇠.

지름길 관계

자주 함께 답이 되는 문서쌍에 증거를 보고 타입드 관계를 뚫어, 다음 검색은 한 번에 도달.

SHS Final Benchmark 100

judge: gpt-5.3-codex

Final Score

0.7641

recall 30% · precision 20% · completeness 25% ·
faithfulness 25% 가중 종합

판정 분포 (100문항)



■ Pass 38 ■ Partial 55 ■ Fail 7

Evidence Recall (30%)



0.7999

Evidence Precision (20%)



0.6770

Answer Completeness (25%)



0.7342

Faithfulness (25%)



0.8207

- **Faithfulness** 최고 — 근거 있는 검색 기록으로만 학습하는 설계가 환각을 억제.
- **Precision**이 병목 — 넓은 회수의 대가. partial 55건의 주요 원인 추정.
- **돌릴수록 좋아짐** — 반복 실행에서 회수 지표 지속 상승, 롤백 없이 완주.