

GRAPH-EVOLVING AGENT ON LIGHTRAG

Evolving LightRAG

쿼리 로그 · 리트리브 결과 · 코퍼스 메타데이터를 근거로
스스로 그래프를 넓혀가는 에이전트 RAG

위키 대신, 그래프 자체를 진화시킨다

- **영감** Karpathy의 LLM Wiki — "지식이 계속 정비되는 시스템"
- **차이점** 위키 페이지를 사람이 다듬는 게 아니라, LightRAG의 지식 그래프 자체를 질문이 쌓일 때마다 에이전트가 계속 진화시킴
- **기반** LightRAG (HKUDS, 2024) — 엔티티/관계 추출 + 그래프 기반 검색
- **핵심** 매번 새로 추론하지 않고, 이미 쌓인 근거(쿼리 로그·리트리브 결과·코퍼스 메타데이터)를 조합해 개선

전체 흐름: 세 단계

1. 쿼리분석·전략선택·유저응답

- 질문을 검색 최적화 형태로 분석
- 곧바로 사용자에게 답변 리턴

2. 로깅 및 로그분석

- 리트리브 결과를 채점(quality)
- 쿼리 로그·메타데이터 추적

3. 그래프 개선

- 쌓인 로그·메타데이터를 근거로
- 그래프를 확장/정리

질문이 쌓일수록 그래프가 조금씩 뚝뚝해지는 사이클 — 1은 즉시(전경), 2·3은 백그라운드에서 돌아 사용자 응답을 지연시키지 않습니다. 개선 결과는 다음 쿼리부터 반영됩니다.

질문 분석부터 즉시 응답까지

ANALYZE

- 질문을 검색 최적화 쿼리로 재작성
- 여러 정보 요구면 서브쿼리로 분해
- 문서 언급 감지(mentioned_docs)

전략 선택

- optimized_query → RESPOND
- sub_queries → 백그라운드 로깅
- mentioned_docs → 문서 스코핑
- 세 갈래 동시 실행

RESPOND (유저응답)

- 최적화 쿼리로 즉시 검색·답변
- 그래프 개선을 기다리지 않음
- 문서 매치 시 검색 범위 축소

문서 스코핑 — ANALYZE가 특정 문서를 지칭한다 판단하면, 그래프 개선이 만든 `doc::` 노드를 찾아 그 문서의 CONTAINS 엔티티로 검색 범위를 좁힙니다. 매치가 없으면 조용히 전체 그래프 검색 (fail-safe).

에이전트 흐름 — foreground + background

ANALYZE 한 번의 호출로
두 경로가 동시에 진행됩니다.

① **RESPOND** — 사용자에게 즉시 응답

② **백그라운드 큐** — 로깅 → 그래프 개선

(tier1 매 쿼리 · tier2 N쿼리마다)



그래프 개선의 유일한 입력을 만드는 단계


- **RETRIEVE** 서브쿼리마다 독립 리트리브 + 로그 축적
- **EVALUATE** quality 점수(0.0~1.0) 산출 · 0 LLM
- **메타데이터** query_log · access_count · last_accessed
- **로그 분석** co-retrieval·gap·반복경로 탐지 → 3단계 트리거

결과	quality
엔티티 0 + 청크 0	0.0
엔티티 0 · 관계 X	0.3
청크만 0 · 엔티티 X	0.4
엔티티+관계+청크	0.5~1.0

quality는 개선 실행을 막는 게이트가 아니라 (tier1은 항상 실행) 로그 분석·모니터링용 신호로 남습니다.

3. 그래프 개선

7가지 방식 · 두 티어 · weight로 원본과 구분



실행 티어

- **Tier 1** 매 쿼리 · co-retrieval/gap/shortcut · 예산 10
- **Tier 2** N쿼리(50)마다 · 근거상실 제거·모순통합·구조 마이닝 · 예산 30

weight — 원본과 구분

출처	weight
원본 문서 LLM 추출	1.0
로그 기반 추론	0.5
구조 마이닝	0.3

그래프 개선 7개 전략 중 LLM은 단 3곳

LLM 사용 0

- co-retrieval — 두 엔티티 관계 설명 생성
- gap filling — 청크에서 엔티티/관계 재추출
- 모순 통합(tier2) — description 병합
- llm_func 없으면 조용히 스킵 (fail-safe)

LLM 사용 X — 규칙/메타데이터

- shortcut — 기존 엣지 설명 이어붙이기
- source verification — source_id 확인만
- 구조 마이닝 3종 — 메타데이터만 사용
- quality 점수 — 순수 규칙, 0 LLM

수동 관찰치 — 정식 데이터셋·스크립트는 TODO

구성	정확도
vanilla LightRAG	~69%
Evolving LightRAG	64% ~ 72%

실행마다 변동 —

잘 나올 땐 +3%p, 나쁠 땐 -5%p

- 관찰 항상 vanilla보다 낮지는 않음
- 원인 구조 마이닝 엣지가 weight 0.3에도 검색 노이즈로 작용
- 근거 문서 ↑ → 구조 엣지가 원본 의미 관계 엣지를 압도

다음 단계: 구조 그래프 분리

구조 그래프 분리 (최우선)

- 구조(문서-문서/청크-청크)를 기존 KG에 주입하지 않고 별도 그래프로 구축·진화
 - 검색: 구조 그래프 먼저 탐색 → 후보 문서/청크로 범위 축소 → 그 안에서 KG 탐색
 - 벤치마크 노이즈 문제(72%→64% 변동)에 대한 직접 대응
-
- 재현 가능한 데이터셋·스크립트로 vanilla vs Evolving 정량 비교
 - 분리 후 구조 관계가 멀티홉 질의에 실제 도움 되는지 재검증
 - confidence decay · human-in-the-loop 승인

한계

현재는 아키텍처 제안 + 프로토타입 단계

- 노이즈 누적 (실측) 벤치마크 정확도가 개선/악화를 오감을 확인
- 수확 체감 반복 3회 이후 이득 급감 — 예산 제한으로 대응
- LLM 추출 정확도 도메인별 60–85% — gap filling도 실수 반복 가능
- 단일 워커 직렬화 동시성 안전 트레이드오프 — 빈번한 워크로드에선 큐 지연
- LLM Wiki 대비 인간 가독성·confidence decay·승인 단계 미구현

REFERENCES

- Karpathy's LLM Wiki (gist, 2026.04)
- LightRAG — HKUDS, 2024 (arXiv:2410.05779)
- On the Evolution of Knowledge Graphs: A Survey (2310.04835)
- NoGE: Node Co-occurrence GNN for KG Link Prediction (2104.07396)
- SMORE: KG Completion & Multi-hop Reasoning (2110.14890)
- Practical GraphRAG: Hybrid Retrieval at Scale (2507.03226)
- Self-Improving RAG for KG Construction (ISCRAM)
- RAG Survey: Noise and Robustness (2506.00054)
- Iterative GraphRAG: Diminishing Returns (2509.25530)

전체 문서: [harness_pjt/README.md](#) · [harness_pjt/ARCHITECTURE.md](#)

Thank you

harness_pjt — Evolving LightRAG